

Research Meeting

Shun Yamachika

Department of Informatics, School of Science and Technology

Kwansei Gakuin University

Sanda, Hyogo, Japan

shun@lsnl.jp

問題設定

ストーリーの骨格

- 背景 量子ネットワークにおいて忠実度を高いリンクを効率的に判定する手法 LinkSelFiE が提案されている
- 動機 LinkSelFiE は通信需要を考慮していないが、現実には通信需要が高くかつ忠実度の高いリンクの判定が望まれる
- 目的 少ない計測 (バウンス) により利用率 $\times$ 忠実度が高いリンクの判定を可能とする

ストーリーの骨格での質問

- 目的 少ない計測 (バウンス) により利用率 $\times$ 忠実度が高いリンクの判定を可能とする

とあるが、重要度 $\times$ 忠実度ではないのか？

- 各リンクに対する通信需要 (demand) を重みとし、需要 $\times$ 忠実度が高いリンクを判定する
- 通信需要に基づく実際の利用率を指標とし、利用率 $\times$ 忠実度が高いリンクを判定する。

抽象的なのは重要度、具体的なのは利用率。

少ない計測 (バウンス) により利用率 $\times$ 忠実度が高いリンクの判定を可能とする

固定予算下のバウンスで。。。

固定予算下かどうか？

現在の問題設定

ノード $s \sim$ ノード d 間のリンク集合 L だけでなく、ノード $S \sim$ ノード D_n 間のリンク集合 L_n ($1 \leq n \leq N$, N はノード S の隣接ノード数) がそれぞれ入力される。ノード $S \sim$ ノード D_n 間の重要度 I_n ($0 \sim 1$ の値) が入力として与えられる。総バウンスコスト C が入力として与えられる。この時、ノード $S \sim$ ノード D_n のノードペアの中で、 K 個のノードペア $(S, D_{s_1}), (S, D_{s_2}), \dots, (S, D_{s_K})$ における忠実度が最大のリンクをそれぞれ発見する。ただし、発見するリンクのノードペア数 K は、重要度と忠実度の積の総和、つまり $I = \sum_{k=1}^K I_{s_k} \times F_{s_k}$ が最大となるように定める。ここで F_n は (S, D_n) 間において忠実度の最大のリンクの忠実度である。重要度は忠実度と対等な重みをもたせるために正規化をする。 ($0 \sim 1$)

問題設定において追加の定義が必要なところ

重要度の分布: 重要度は忠実度と対等な重みをもたせるために正規化をする。

K は静的に決まるもの?: 重要度 I も忠実度 F も正の値 ($0 \leq I, F \leq 1$) であるため、積 $I \times F$ は常にプラスになる。したがって、「総和を最大にする K 」を求めると、常に $K=N$ (全ての宛先を選択する) ことが答えになってしまう。

静的にきまる $\rightarrow$ 同時に通信可能な宛先数 K がハードウェア制約として与えられたとき、限られたバウンス予算のもとで、重要度と忠実度の積の総和を最大化する K 個の宛先選択とリンク判定を同時に行う手法を提案する。

K が入力として与えられる

きいてみる

K の扱い: 「 K 個選ぶ」のか、それとも「スコアの総和を最大化するために K も最適化対象とする (ナップサック問題のアプローチ)」のか、厳密な再確認。

予算を C で固定しない: 固定予算下でリンク除去をする問題と、宛先を複数に拡張し、2 層 (宛先、リンク) の除去を行なう問題が複合している。

linkselfie は最適リンクを確率 $1 - \delta$ 以上で正しく推定する手法。予算のことは考えていない。

- linkselfie

Lemma 1 的除去は、信頼区間に基づいて除去を判断します。ある腕の推定値の上側信頼限界が、最良腕の推定値の下側信頼限界を下回ったときに初めて除去します。つまり「統計的に有意に劣っていると判断できるものだけを落とす」というルールです。

Lemma 1 的除去は固定信頼度設定に対応します。信頼パラメータ δ が先に決まっており、確率 $1 - \delta$ 以上で正しく識別することを保証しつつ、必要なサンプル数 (コスト) を最小化することが目標です。識別が完了するまでアルゴリズムは停止せず、コストは問題の難易度に応じて変動します。

- 固定予算

SR 的除去は、各フェーズ終了時に推定値が最低の腕を機械的に除去します。推定値の信頼性や他の腕との差の統計的有意性は考慮しません。「現時点で一番悪く見えるものを落とす」という単純なルールです。

SR 的除去は固定予算設定に対応します。総サンプル数 (予算) C が先に決まっており、その制約下で誤識別確率を最小化することが目標です。予算が尽きた時点でアルゴリズムは停止し、その時点での最良推定腕を出力します。

LINKSELFIE は Lemma 1 的除去を採用しており、その強みは非線形回帰に基づく信頼区間が Hoeffding 不等式より狭いことでした。この強みを活かすには、拡張手法も固定信頼度設定を維持すべきです。固定予算設定で SR 的除去を採用すると、Lemma 1 の信頼区間を使う理論的根拠が失われ、LINKSELFIE との差別化も弱くなります。

よって、固定予算 C を入力するのではなく、代わりに信頼度パラメータ δ を入力するようにするといいいかもしれない。

確率 $1 - \delta$ 以上で、宛先選択とリンク特定の両方が正しい。つまり、目的関数が確率 $1 - \delta$ 以上で最大値をとる。

Fixed Confidence: 入力 δ 。コストは結果（最小化対象）。「正解率は保証するから、なるべく安く済ませて」

Fixed Budget: 入力 C 。誤り率は結果（最小化対象）。「予算はこれだけだから、この範囲でベストを尽くして」

NEW 問題設定 (簡条書き形式)

入力 (Inputs)

- ネットワーク構成: ソースノード S と、その近傍に位置する N 個の宛先ノード集合 $\mathcal{D} = \{D_1, D_2, \dots, D_N\}$
- リンク集合: 各ノードペア (S, D_n) 間を結ぶ、候補となる量子エンタングルメントリンクの集合 $\mathcal{L}_n = \{l_{n,1}, l_{n,2}, \dots, l_{n,M_n}\}$
- 重要度: 各宛先 D_n に対する通信の優先度を表す重み $I_n \in (0, 1]$ (既知の定数)
- 通信制約: 同時に確立すべき通信パスの上限数 K ($1 \leq K < N$)
- 信頼度パラメータ: 許容される誤識別確率の上限 $\delta \in (0, 1)$

未知のパラメータ (Unknown Parameters):

- リンク忠実度: 各リンク $l \in \mathcal{L}_n$ の真の平均忠実度 $F_{n,l} \in [0.5, 1.0]$

これらは未知であり、ネットワークベンチマーキング (NB) によってのみ推定可能

目的

以下の目的関数 $J(\mathcal{S}_{\text{out}}, \mathcal{L}_{\text{out}})$ を最大化するような、サイズ K の宛先部分集合 $\mathcal{S}_{\text{out}} \subset \mathcal{D}$ および、各選抜宛先における最良リンクの集合 $\mathcal{L}_{\text{out}} = \{l_n^* \mid D_n \in \mathcal{S}_{\text{out}}\}$ を特定する。

$$\text{Maximize } J = \sum_{D_n \in \mathcal{S}_{\text{out}}} I_n \cdot F_{n,l_n^*}$$

ここで、 $F_{n,l_n^*} = \max_{l \in \mathcal{L}_n} F_{n,l}$ は宛先 D_n における真の最大忠実度である。

要件と評価指標 (Requirements & Metric):

- δ -正解性: アルゴリズムが出力する解が真の最適解と一致する確率が、少なくとも $1 - \delta$ 以上であること。
- サンプル複雑性の最小化: 上記の正解性を満たしつつ、アルゴリズム停止までに要する総バウンス数 (Total Bounce Cost) を最小化すること。

NEW 問題設定 (文章形式)

I. PROBLEM FORMULATION

本研究では、量子ネットワークにおけるリソース制約と宛先重要度を考慮したリンク選択問題を扱う。ソースノード S と N 個の宛先ノード $\mathcal{D} = \{D_1, \dots, D_N\}$ からなるスター型トポロジーを想定する。各ノードペア (S, D_n) 間には複数の物理的経路等に由来する候補リンク集合 $\mathcal{L}_n$ が存在し、各リンク $l \in \mathcal{L}_n$ は未知の忠実度 $F_{n,l}$ を持つと仮定する。また、各宛先 D_n には、アプリケーション層の要求に基づく重要度 $I_n \in (0, 1]$ が付与されている。

本問題の目的は、同時に通信可能な宛先数が K ($K < N$) に制限された状況下で、システム全体の「重要度重み付き忠実度和」を最大化する通信構成を決定することである。まず、各宛先 D_n の潜在的な価値 (スコア) V_n を、その宛先が持つ最良リンクの忠実度を用いて次式で定義する。

$$V_n = I_n \cdot \max_{l \in \mathcal{L}_n} F_{n,l} \quad (1)$$

最適化の目標は、スコア V_n が高い上位 K 個の宛先集合 $\mathcal{S}_{\text{out}}$ を特定し、かつ各宛先 $n \in \mathcal{S}_{\text{out}}$ について最適なリンク $l_n^* = \arg \max_{l \in \mathcal{L}_n} F_{n,l}$ を特定することである。すなわち、以下の目的関数 J を最大化する解を求める。

$$\text{Maximize } J(\mathcal{S}_{\text{out}}) = \sum_{D_n \in \mathcal{S}_{\text{out}}} V_n = \sum_{D_n \in \mathcal{S}_{\text{out}}} I_n \cdot F_{n,l_n^*} \quad (2)$$

本設定は、多腕バンディット問題における「固定信頼度 (Fixed Confidence) 設定の最適腕識別問題」の拡張として定式化される。アルゴリズムには、信頼度パラメータ $\delta \in (0, 1)$ が入力として与えられる。アルゴリズムはネットワークベンチマーキング (バウンス) を通じてリンク忠実度を推定し、逐次的に宛先およびリンクの取捨選択を行う。最終的に出力される宛先集合およびリンク集合が真の最適解と一致しない確率 (誤識別確率) を δ 以下に抑えつつ、その達成に必要な総バウンス数 (Sample Complexity) を最小化することを最適化の指標とする。

骨格をもとに構築したストーリー案

背景

量子ネットワークでは、ノード間のエンタングルメントリンクの忠実度が通信品質を決定する重要な指標である。忠実度はネットワーク状態の変動に伴い変化するため、通信に先立ち高忠実度のリンクを判定する必要がある。この問題に対し、限られた計測回数 (バウンス) のもとで送受信ノード間の最大忠実度リンクを効率的に特定する手法として LinkSelFiE が提案されている。

動機

しかし LinkSelFiE は単一の送受信ノードペアのみを対象としている。現実の量子ネットワークでは、量子スイッチや QKD アクセス網のように一つのノードが複数の宛先と同時に通信需要を持つ場面が存在する。各宛先への需要の重要度は一様ではなく、限られたバウンス予算を重要度に応じて複数宛先間で適切に配分しながらリンクを判定する仕組みが求められる。

目的

本研究では LinkSelFiE を複数宛先・通信需要を考慮した設定に拡張する。具体的には、各宛先の重要度と忠実度の積の総和を最大化するように、限られたバウンス予算のもとで検証すべき宛先の選択と各宛先における最大忠実度リンクの判定を同時に行う手法を提案する。これにより資源制約下で実用的なリンク選択が可能となる。

手法

II. 提案アルゴリズム: MD-LINKSELFIE

A. 概要

本稿で提案する MD-LINKSELFIE (Multi-Destination LINKSELFIE) は、フェーズベースの二重除去 (Dual

Elimination) アルゴリズムである。本アルゴリズムは、各フェーズにおいて生存しているリンクに対してネットワークベンチマーキングを行い、推定精度を段階的に向上させる。フェーズの終了時には、得られた信頼区間に基づき、以下の二つの除去メカニズムを適用する。

- **内層除去 (Inner Elimination):** 各宛先 n 内部において、最良リンクとなる可能性が統計的に否定された劣等なリンクを除去する。
- **外層除去 (Outer Elimination):** 宛先集合全体において、重要度重み付き忠実度が上位 K 位以内に入る可能性が統計的に否定された宛先を除去する。

これら二つのメカニズムは、停止条件が満たされるまで統合されたループ内で並行して実行される。除去判定は厳密な信頼区間に基づいて行われるため、真の最良リンクや真の上位 K 宛先が誤って除去される確率は、許容誤差パラメータ δ 以下に抑えられる。

B. 初期化

全 N 個の宛先をアクティブ宛先集合 $\mathcal{A}$ に格納する。各宛先 $n \in \mathcal{A}$ について、その宛先に属する全リンクをアクティブリンク集合 $\mathcal{S}_n$ に格納する。フェーズカウンタを $s \leftarrow 1$ とし、累積反復回数を $T_0 \leftarrow 0$ に初期化する。

C. アルゴリズムの実行

以下の停止条件が満たされるまで、フェーズ $s = 1, 2, \dots$ を繰り返す。

- **停止条件:** アクティブな宛先数が K 以下であり ($|\mathcal{A}| \leq K$)、かつ全てのアクティブ宛先 $n \in \mathcal{A}$ において候補リンクが 1 本に絞られている ($|\mathcal{S}_n| = 1$)。

各フェーズでは以下の手順を実行する。

1) 1. 反復回数の設定: フェーズ s における累積反復回数 T_s を次式で設定する。

$$T_s = C_{NB} \cdot 2^{2s} \cdot \log \left(\frac{(s+1)(s+2)NL_{\max}}{\delta} \right) \quad (3)$$

ここで、 C_{NB} は Lemma 1 により定まる定数、 $L_{\max}$ は宛先あたりの最大リンク数である。本フェーズで追加実行する反復回数は $\Delta T = T_s - T_{s-1}$ である。

2) 2. ベンチマーキングと推定: 各アクティブ宛先 $n \in \mathcal{A}$ の各アクティブリンク $l \in \mathcal{S}_n$ に対して、ネットワークベンチマーキングを ΔT 回実行する。各バウンズ数 $m \in \mathcal{M}$ における生存確率の測定値について、前フェーズまでの累積データと統合し、更新された平均生存確率 $b_{n,l,m}^{(s)}$ を算出する。

$$b_{n,l,m}^{(s)} = \frac{b_{n,l,m}^{\text{new}} \cdot \Delta T + b_{n,l,m}^{(s-1)} \cdot T_{s-1}}{T_s} \quad (4)$$

この累積データを指数モデル $b_m = Ap^{2m}$ にフィッティングし、各リンクの脱分極パラメータ推定値 $\hat{p}_{n,l}^{(s)}$ を得る。

3) 3. 信頼半径の計算: Lemma 1 に基づき、フェーズ s における脱分極パラメータ p に対する信頼半径 ε_s を計算する。

$$\varepsilon_s = \sqrt{\frac{C_{NB}}{T_s} \cdot \log \left(\frac{(s+1)(s+2)NL_{\max}}{\delta} \right)} \quad (5)$$

このとき、全ての n, l, s において、確率 $1 - \delta$ 以上で $|\hat{p}_{n,l}^{(s)} - p_{n,l}| \leq \varepsilon_s$ が成立する。

4) 4. 内層除去 (リンク選抜): 各アクティブ宛先 $n \in \mathcal{A}$ について、リンク集合 $\mathcal{S}_n$ 内の最大推定値 $\hat{p}_{\max,n} = \max_{l \in \mathcal{S}_n} \hat{p}_{n,l}^{(s)}$ を特定する。上側信頼限界が暫定最良リンクの下側信頼限界を下回るリンクを除去する。

$$\mathcal{S}_n \leftarrow \mathcal{S}_n \setminus \left\{ l \in \mathcal{S}_n : \hat{p}_{n,l}^{(s)} + \varepsilon_s < \hat{p}_{\max,n} - \varepsilon_s \right\} \quad (6)$$

除去後、宛先 n の代表忠実度推定値 $\hat{F}_n$ および重要度重み付きスコア推定値 $\hat{V}_n$ を更新する。

$$\hat{F}_n = \frac{\hat{p}_{\max,n} + 1}{2}, \quad \hat{V}_n = I_n \cdot \hat{F}_n \quad (7)$$

5) 5. 外層除去 (宛先選抜): 現在のアクティブ宛先数が K を超えている場合 ($|\mathcal{A}| > K$)、宛先の除去を行う。各宛先 n のスコア $\hat{V}_n$ に対する信頼半径は $I_n \cdot \varepsilon_s / 2$ となるため、スコアの上側信頼限界 (UCB) と下側信頼限界 (LCB) は次式で与えられる。

$$\text{UCB}_n = I_n \left(\hat{F}_n + \frac{\varepsilon_s}{2} \right), \quad \text{LCB}_n = I_n \left(\hat{F}_n - \frac{\varepsilon_s}{2} \right) \quad (8)$$

アクティブ宛先集合 $\mathcal{A}$ の中で K 番目に大きい下側信頼限界を閾値 $\Theta_K = \text{LCB}_{(K)}$ とする。上側信頼限界がこの閾値を下回る宛先は、上位 K 位に入る可能性がないため除去する。

$$\mathcal{A} \leftarrow \mathcal{A} \setminus \{ n \in \mathcal{A} : \text{UCB}_n < \Theta_K \} \quad (9)$$

6) 6. フェーズ更新: フェーズカウンタを更新し ($s \leftarrow s + 1$)、次のフェーズへ移行する。

D. 出力

アルゴリズム停止時、アクティブ宛先集合 $\mathcal{A}$ は最適な K 個の宛先を含み、かつ各宛先 $n \in \mathcal{A}$ のリンク集合 $\mathcal{S}_n$ は唯一の最良リンクを含んでいる。これを最終的な通信経路として出力する。

信頼度 δ の扱いについて

linkselfie における δ

守備範囲: 「ある 1 つの宛先」に対するリンク選択のみ。
意味: 選ばれたリンクが、実は最良ではない (本当はもっと良いリンクがあったのに捨ててしまった) 確率が δ 以下。
今回の問題設定における信頼度パラメータ δ

守備範囲: 「全 N 宛先」の選定と、「その中のリンク」選択のすべて。

意味: 以下の 2 種類のミスのどちらか一方でも発生する確率の合計が δ 以下。

ミス A (宛先選択のミス): 本当はスコア (重要度 $\times$ 忠実度) が高く、トップ K に入るべき宛先を、誤って「圏外」と判断して捨てること。

ミス B (リンク選択のミス): 選ばれた宛先の中で、本当はもっと忠実度が高いリンクがあるのに、誤って低品質なリンクを代表として選んでしまうこと。

= アルゴリズムが最終的に出した答えが、本当の最適解 (正解) と一致しない確率の上限

つまり、 $1 - \delta$ = アルゴリズムが正しく最適解を出力する確率を表わす。

エンタングルメント生成にかかる費用を計算する

結論 距離によって変化するが、ほぼ 0 円

Q. エンタングルメント生成機器の値段を考慮しない場合、100km 離れたノード A,B 間で 1 エンタングルメント生成するのにかかるコストは何円くらいですか？

- chatGPT 十円～数百円/回
- gemini 1 ペアあたり約 0.00001 円 ～ 0.001 円程度
- claude 約 1～10 円/ペア
- grok 約 0.03 円

エンタングルメント成功確率は距離によって指数関数的に減衰するため、1 エンタングルメント生成コストは距離に応じて指数関数的に高くなる。(生成試行回数が増えるから)

じゃあなぜエンタングルメントは高コストと言われているのか？

エンタングルメントの生成成功率が極めて低く、品質維持も困難だから。

量子通信はエンタングルメントを消費して通信をする。現在の技術では、ノイズの影響やハードウェアの未熟さにより、エンタングルメントを高速かつ大量に生成することが極めて困難である。通信距離が伸びるほど、指数関数的にエンタングルメント生成成功率が低下するため、一つ一つのエンタングルメントが貴重な資産となる。さらにエンタングルメントが生成された直後から量子状態の崩壊(デコヒーレンス)が始まるため、貯蓄することも難しいから。

実際に生成されているエンタングルメントがどの程度理想状態を保っているか(忠実度)を把握するには、生成されたエンタングルメントの一部をサンプルとして測定し、統計的に推定する必要がある。忠実度の推定精度を上げるにはサンプル数を増やす必要があるため、品質推定に回す分だけデータ送信に利用できるエンタングルメントが減るというトレードオフが生じる。

例) ノード A,B 間でエンタングルメント生成をするとき
エンタングルメント生成試行 (1 秒間に 1000 回試行)

↓

エンタングルメント成功 (100 回に 1 回成功するとしたら
1 秒間に 10 個エンタングルメントが生成される)

↓

エンタングルメントが理想状態にどれくらい近いか(忠実度)を把握する必要がある。1 秒間に 2 個のエンタングルメントを消費し、忠実度を監視する

↓

通信で利用できるエンタングルメントは 1 秒間に 8 個
(量子メモリの保持時間は現状ミリ秒～秒オーダーが限界のため、使用しなかったエンタングルメントは消失する)

厳密にはエンタングルメントの生成速度や距離の減衰は量子ビットのプラットフォームに大きく依存する。

40 バウンスが高コストなのかどうか

エンタングルメント生成にかかるコストは上述した通り、コストに比例して指数関数的に増えていくので距離によるが、非常に高コストであると言える。

以下、claude Opus4.5 で調査した結果

距離	主な制約	現実的なレート
1 km 未満	光子損失小、高レート可能	10-1000 Hz
1-50 km	ファイバー損失 (0.2dB/km)	0.1-10 Hz
50-100 km	量子メモリ必須	mHz-Hz
100 km 以上	量子リピータ/衛星必須	実験段階

現状は距離が離れていると実用的な通信はできない。40 バウンスも 80 エンタングルメント (40 x 2(往復する) = 80) を使用するのだから当然高価である。

しかし、現在の量子ネットワークを想定するのなら、高効率化、高精度化がなぜ必要なのか？ 工学的に本当に必要なのか？ -ohsaki

例

- 一食 12.7 円のカレーライスを 11.4 円にしてもほぼ実用上は意味がない (最初からタダ同然だから)
- 一食 12.7 万円のカレーライスを 11.4 万円にしてもほぼ実用上は意味がない (もともと高すぎて食べられないから)
- 一食 1200 円のカレーライスを 600 円にしたなら意味がある (1200 円なら無理でも、600 円なら出せる (人であれば))

この例でいうと、一食 12.7 万円のカレーライスを 11.4 万円にする研究になっている。しかし、数年後にはもっと安くなるし、近い距離の通信を想定すれば安くなる。

補足

linkselfie、NB は抽象的なネットワークモデルに基づいており、以下の 3 つの機能を持つノードであれば、基礎となるハードウェアに関わらず適用できるとされている。

- 量子メモリ: 量子状態を保存する能力 (例: 初期化や読み出しが可能であること)。
- 量子操作: 保存された量子状態に対して量子ゲート操作を行う能力 (ユニタリ 2-デザインなどの特定のゲートセットが必要)。
- 量子状態の転送: ノード間で量子状態を送信する能力 (例: もつれを用いたテレポーテーションなど)。

なので、将来的に新たなハードウェアが台頭してきても適用できる可能性が高い。(NB より優秀な手法が考案される可能性はある)

現行ストーリーの問題設定における提案

ストーリーの骨格

- 背景 量子ネットワークにおいて忠実度を高いリンクを効率的に判定する手法 LinkSelFiE が提案されている
- 動機 LinkSelFiE は通信需要を考慮していないが、現実には通信需要が高くかつ忠実度の高いリンクの判定が望まれる
- 目的 少ない計測 (バウンス) により利用率 x 忠実度が高いリンクの判定を可能とする

現在の問題設定

ノード s ~ ノード d 間のリンク集合 L だけでなく、ノード S ~ ノード D_n 間のリンク集合 L_n (1 ≤ n ≤ N, N はノード S の隣接ノード数) がそれぞれ入力される。ノード S ~ ノード D_n 間の重要度 I_n (0 ~ 1 の値) が入力として与

えられる。総バウンスコスト C が入力として与えられる。この時、ノード $S \sim$ ノード D_n のノードペアの中で、 K 個のノードペア $(S, D_{s_1}), (S, D_{s_2}), \dots (S, D_{s_K})$ における忠実度が最大のリンクをそれぞれ発見する。ただし、発見するリンクのノードペア数 K は、重要度と忠実度の積の総和、つまり $I = \sum_{k=1}^K I_{s_k} * F_{s_k}$ が最大となるように定める。ここで F_n は (S, D_n) 間において忠実度の最大のリンクの忠実度である。

提案

• 変更前

重要度と忠実度の積の総和、つまり $I = \sum_{k=1}^K I_{s_k} * F_{s_k}$ が最大となるように定める。

• 変更後（修正案）

物理的な通信可能性を考慮した有効効用（Effective Utility）の総和、つまり

$$U_{\text{total}} = \sum_{k \in S} I_k \times \max(0, F_k - F_{\text{th}})$$

が最大となるように定める。（ここで F_{th} は通信に必要な最低忠実度である。）

物理的な動機

量子通信には『使えない領域』と『使える領域』の明確な境界がある

単純な線形モデル（ $I \times F$ ）では、忠実度 0.5（完全なノイズ）であっても、重要度 I が高ければ正の価値を持ってしまう。

しかし実際の量子ネットワーク（QKD やエンタングルメント蒸留）では、忠実度がしきい値 F_{th} を下回ると、生成レートや蒸留収率は厳密にゼロになる。

したがって、物理的な実態を反映するには、しきい値以下を無価値（ゼロ）とするモデルが不可欠である。

例

- リンク A（ゴミ）：重要度 $I=1.0$ (Max)、忠実度 $F=0.5$ (通信不可)
- リンク B（優良）：重要度 $I=0.4$ (低め)、忠実度 $F=0.99$ (超高品質)

例え重要度が高くても使えないリンクのほうが価値が高くなってしまうのはおかしい。

アルゴリズム的な動機

忠実度 0.91 と 0.92 の差は、絶対値で見ればわずか約 1% である。単純な掛け算（ $I \times F$ ）では、この差が重要度 I の大小に埋もれてしまう。

しかし、しきい値が 0.90 の場合、この差は「マージン（有効品質）」の観点では 0.01 対 0.02 となり、2 倍（100%）の性能差に相当する。

この「有効な差」を強調（コントラスト増幅）することで、探索アルゴリズム（Bandit）が低コストで正解を見つけやすくなる。

複雑な物理式を避けつつ、上記の特性（しきい値以下カット、および有効成分の強調）を満たす最もシンプルな形として、以下を定義する。

$$U = I \times \max(0, F - F_{\text{th}})$$

用語の説明


蒸留とは、複数の低品質なエンタングルメント対を消費して、高品質なペアを抽出（純粋化）するプロトコルである。このプロセスにおいて、初期忠実度が特定のしきい値 F_{th} （例: 0.5 やそれ以上の特定値）を下回っている場合、どんなに多くのペアを消費しても忠実度を向上させることは不可能（蒸留不能）となる。

QKD においては、量子ビット誤り率（QBER）が保安限界（例: BB84 プロトコルにおける約 11%）を超過すると、盗聴者による情報漏洩の可能性を排除できなくなる。忠実度 F は誤り率と相関するため、これは F がある閾値を下回ると秘密鍵生成レートがゼロになることを意味する。

論文での説明のイメージ

効用関数の定義について 量子通信において、忠実度 F がしきい値 F_{th} をわずかに超えた程度では、蒸留効率（Distillation Yield）は極めて低く、実効的な通信レートはゼロに近い。そのため、リンクの効用は単純な F ではなく、しきい値を超過した「有効マージン（Effective Margin）」に比例するとみなすのが物理的に妥当である。よって、本研究では効用関数として $U = I \times \max(0, F - F_{\text{th}})$ を採用する。これは蒸留可能エンタングルメント量（Distillable Entanglement）や秘密鍵レートの一次近似に相当する。

複数の宛先をどのように解釈するか



円はノード、楕円は中継ノード (量子リピータ)、実線はリンクを表わす。

このとき、linkselfie では

(S → D₁ → D) x 2 本 (S → D₂ → D) x 3 本 (S → D₃ → D) x 2 本

のリンクをそれぞれ別々のエンタングルメントリンクとして扱っていた。(量子リピータなどの中継ノードは抽象化されているため)

本研究では複数の宛先を考慮するが、必ずしも通信先の最終到達地点が違うとは限らない。

手法 (どのような手法でこの問題をとくか)

LinkSelfie はすべてのリンクを公平に扱い、忠実度が低いものを捨てる手法である。今回の提案手法はこれを拡張し、以下の 2 段階の「足切り (Pruning)」を同時に行う。

- ローカルな足切り (Local Pruning) : ある隣接ノード D_n の中で、明らかに性能が劣る物理リンクを捨てる (これは従来の LinkSelfie と同じ)。
- グローバルな足切り (Global Pruning) : 最高まで上振れしても、他ノードの最低保証効用に勝てない隣接ノードを、ペアごと丸ごと捨てる。(全ての宛先に linkselfie との差別化)

できれば、最大推定忠実度が閾値を満たさなそうなりリンクも、ローカル、グローバルで捨てたい。

具体的なアルゴリズムの手順

この手法は「フェーズベース (Phase-based)」で進行する。

- 初期化と疎なサンプリング:
まず、全ての隣接ノード D_n の全ての物理リンクに対して、ごく少数のバウンス (計測) を行い、リンクの忠実度推定値 $\hat{F}_n$ と、広い信頼区間幅 β を得る。
- 効用の信頼区間 (Utility Confidence Bound) の計算
a) 最大効用 (Upper Confidence Bound of Utility) :

$$U_n^{\max} = I_n \times \max \left(0, (\hat{F}_n + \beta_n) - F_{\text{th}} \right) \quad (10)$$

b) 最低保証効用 (Lower Confidence Bound of Utility) :

$$U_n^{\min} = I_n \times \max \left(0, (\hat{F}_n - \beta_n) - F_{\text{th}} \right) \quad (11)$$

※ ここで $\hat{F}_n$ は、そのノードペア内で現在生き残っている最良リンクの推定値。

- グローバルな除去 (ノードごとの脱落判定)
現在生き残っている全隣接ノードの中で、最も有望なノードの最低保証 (Ubestmin) を特定します。
もし、あるノード D_k の「最大効用 (Ukmax)」が、この Ubestmin よりも低ければ、ノード D_k は即座に探索対象から除外する。
判定式: $U_{\{\text{best}\}^{\{\min\}}} = \max_{n \in D} U_n^{\{\min\}}$ ならば D_k を除去。
- 予算配分と再計測
生き残ったノードペアに対してのみ、LinkSelfie のロジックで次フェーズのバウンス数を割り当てます。これを予算が尽きるか、1 つの最適解が残るまで繰り返す。

この研究の分野

関連研究を調べたところ、全く同じ研究は存在しなかった。似ている研究

- 量子ネットワーク効用最大化 (QNUM) 忠実度が既知である前提で、各ユーザーペアの効用 U をレート R と忠実度 F の関数 (例: $U = w \log(R \cdot f(F))$) として定義し、その総和を最大化する。
- Quantum Algorithms for Bandits with Knapsacks 予算制約付きバンディット問題について触れている。一般的な数理モデルとしての「量子アルゴリズム」に焦点を当てており、量子ネットワークの物理層 (忠実度推定の回帰モデルや物理的バウンスコスト) への具体的な適用については言及していない。

量子ネットワークで予算制約下でのバンディット問題 x 効用最大化を扱っている研究がない

これまでやったこと

ソサイエティ

通信需要 (リンク利用率) を重みとして導入し、有限なバウンスコスト下で需要×忠実度スコアが最大となるリンクを選定可能とする評価手法を考案した。

ソサイエティ後

先生から頂いた ai との対話の抜粋: ノード $s \sim$ ノード d 間のリンク集合 L だけでなく、ノード $S \sim$ ノード D_n 間のリンク集合 L_n ($1 \leq n \leq N$, N はノード S の隣接ノード数) がそれぞれ入力される。ノード $S \sim$ ノード D_n 間の重要度 I_n ($0 \sim 1$ の値) が入力として与えられる。総バウンスコスト C が入力として与えられる。この時、ノード $S \sim$ ノード D_n のノードペアの中で、 K 個のノードペア $(S, D_{s_1}), (S, D_{s_2}), \dots, (S, D_{s_K})$ における忠実度が最大のリンクをそれぞれ発見する。ただし、発見するリンクのノードペア数 K は、重要度と忠実度の積の総和、つまり $I = \sum_{k=1}^K I_{s_k} * F_{s_k}$ が最大となるように定める。ここで F_n は (S, D_n) 間において忠実度の最大のリンクの忠実度である。

$I = \sum_{k=1}^K I_{s_k} * F_{s_k}$ という目的関数を最大化させる手法を考えようとしたが、思いの外少ないコストで忠実度が把握できてしまうことから linkselfie の分析を始めた。具体的には以下のようなことが分かった。

linkselfie のアルゴリズムの流れ:

- 1) 全てのリンクに対し、少量の資源を使い、おおまかな忠実度を推定する。
- 2) 明らかに低い忠実度と判断されたリンクを除外。
- 3) 残ったリンクに追加で資源を使い、より詳しく忠実度を調査する。
- 4) リンクが 1 本 (または n 本) になるまで 2,3 を繰り返す。

このアルゴリズムにおいて、1 に該当する部分でかなり詳しく忠実度が推定できていることが分かった。

具体的には、1 で linkselfie は全てのリンクに対して 40 バウンス ($m = 1, 2, 3, 4 \rightarrow N_m = 4$) 使っている。これは NB の仕様上、最小限に近いバウンスであるがこの時点で推定誤差が 0.03 程度であることが分かった。また、200 バウンスほど消費すると推定誤差は 0.01 程度まで下がった。

NB の実験設定 1 本のリンク $m \sim 20$ 各 $m \sim 40$ 回ずつ linkselfie 1 本 $m \sim 4$ 各 $m \sim 4$ 回ずつ

最大の忠実度のリンクを保証付きでみつける 数千バウンス使う NB は 1 本のリンクの平均忠実度を推定するのに 数千バウンス

しかし、忠実度がある程度把握するのは $m \sim 4$ 各 $m \sim 4$ 回ずつでいける?

1 つの宛先

複数の宛先

この結果は目的関数 $I = \sum_{k=1}^K I_{s_k} * F_{s_k}$ を最大化するうえで、全てのリンクに少量の資源 (例 40 バウンス ($m = 1, 2, 3, 4 \rightarrow N_m = 4$)) を与えるだけでもかなりの高スコアになってしまうことを示唆している。

この実験は linkselfie と同じ実験設定で行なっているため、現実の量子ネットワークで全く同じことが起こるのかは不明だが、linkselfie と同じ実験設定を仮定するのであれば配分方法をこれ以上工夫しても大きな改善は見込めないと判

断した。(素朴な手法である程度の高スコアが達成されてしまっているため)

NB の改善

そこで、linkselfie において忠実度推定のサブルーチンとして使用されている NB の忠実度推定精度を向上させることで、目的関数 $I = \sum_{k=1}^K I_{s_k} * F_{s_k}$ をより少ないコストで効率的に最大化できるのではないかと考えた。最終的に 2 つの手法を考案した。

1 つ目の手法: フィッシャー情報量に基づいて最適な m と測定回数を割りあてる手法を考案した。linkselfie において、NB はバウンス長 m に対して均一な測定回数 N_m を割り当てることを前提としており、情報利得の高いバウンス長に測定回数を集中させるような効率的なリソース配分ができない。

以下のような手法を考えた。

- 1) 複数の m に対して少量のバウンスを使い、おおまかな f を推定。
- 2) 推定された f からフィッシャー情報量を計算し、最も情報量を取得できる m を特定。
- 3) m を測定。
- 4) 1 の測定結果と 3 の測定結果を統合し f を更新。
- 5) 以降、2,4 を繰り返す。

しかし、この手法は

- 同じ m ばかり選択され続けてしまい思った通りの挙動にならず、良い結果が得られない
- 似たような先行研究が存在するため、良い結果が得られたとしても国際会議に通るほどのインパクトは無いかもしれない

という理由で断念した。

2 つ目の手法: NB の特性から、 m ごとの分散が m の大きさに依存して変化することが知られている。しかし、NB では全ての m が等分散であることを仮定しており、最小二乗法によるフィッティングが行なわれている。

そこで重み付き最小二乗法によるフィッティングを行なう以下のような手法を考えた

- 1) 各バウンス数 m について、測定結果の標本標準偏差 $\sigma(m)$ を計算する。
- 2) 平均値 $\bar{b}_m$ の標準誤差を

$$SE(m) = \frac{\sigma(m)}{\sqrt{N_m}} \quad (12)$$

として計算する。

- 1) 各データ点に対する重みを標準誤差の二乗の逆数として定義する

$$w(m) = \frac{1}{[SE(m)]^2} \quad (13)$$

この重み付けにより、ばらつきの小さいデータ点 (推定の信頼性が高い点) には大きな重みが、ばらつきの大きいデータ点には小さな重みが割り当てられる。

- 1) 重み付き残差二乗和

$$S_{WLS} = \sum_{m \in M} w(m) (\bar{b}_m - A f^m)^2 \quad (14)$$

を最小化することでパラメータ A および f を推定する。

TABLE I
FIDELITY ESTIMATION RESULTS ($\alpha = 0.90$, $N=40$)

m range	OLS	WLS
m2-10	0.8215 ± 0.0091	0.8206 ± 0.0070
m2-20	0.8179 ± 0.0076	0.8185 ± 0.0056
m2-30	0.8191 ± 0.0090	0.8191 ± 0.0055

TABLE II
FIDELITY ESTIMATION RESULTS ($\alpha = 0.95$, $N=40$)

m range	OLS	WLS
m2-10	0.9080 ± 0.0063	0.9073 ± 0.0025
m2-20	0.9029 ± 0.0033	0.9029 ± 0.0015
m2-30	0.9006 ± 0.0029	0.9010 ± 0.0013

以下が推定された忠実度である。

不確実性を削減することに成功はしたが、 m の範囲を狭くすると誤った忠実度を吐いてしまう結果が出てしまった。

NB でこのような研究はまだされていないが、NB の基盤となっている RB で似たような研究がされている。NB の作者である Halsen 自身も RB においてフィッティングを OLS ではなく WLS で行なうべきで、WLS の中でも IRLS という方法でフィッティングを行なうべきという論文を出している。

RB と NB の違いを明確化し、NB ならではのコスト効率化をしなければインパクトは薄いと思っている。(今のまま論文を書いてもインパクトは薄い)

NB の説明

ノード A、ノード B 間の通信路の品質を推定する時の動き

- 1) ノード A で量子ビットを用意する。
- 2) ノード A で、ランダムなゲート操作を量子ビットに加える。
- 3) ノード A からノード B へ量子ビットを送信する。
- 4) 受け取ったノード B でも、ランダムな操作を加える。
- 5) ノード B からノード A へ量子ビットを送り返す。(この「 $A \rightarrow B \rightarrow A$ 」の往復を「1 回のバウンス」と呼ぶ)
- 6) このバウンス (手順 2~5) を m 回繰り返す。何度も通信路を通すことで、わざと通信エラーを蓄積させるため。
- 7) 最後に、これまでのランダム操作をすべて打ち消して、元の状態に戻すための「逆操作」をノード A で行う。もし通信路や操作が完璧なら、量子ビットは完全に元の状態に戻る。
- 8) 実際に元の状態に戻っているかを確認 (測定) する。(結果は 0,1 で取得)
- 9) 上記の手順を、操作の組み合わせをランダムに変えながら何度も行い、成功率 (平均生存率) を出す。

TABLE III
FIDELITY ESTIMATION RESULTS ($\alpha = 0.99$, $N=40$)

m range	OLS	WLS
m2-10	0.9752 ± 0.0041	0.9765 ± 0.0004
m2-20	0.9764 ± 0.0018	0.9763 ± 0.0002
m2-30	0.9761 ± 0.0009	0.9762 ± 0.0001

NB プロトコルで得られた出力データ $\{\bar{b}_m\}_{m \in \mathbb{M}}$ は、以下の単一指数関数にフィッティングすることができる：

$$\bar{b}_m = A f^m \quad (15)$$

データ $\{\bar{b}_m\}_{m \in \mathbb{M}}$ に対する指数関数フィッティングに通常最小二乗法 (Ordinary Least Squares, OLS) が用いられる。OLS はすべてのデータ点を等しい重みで扱い、残差二乗和

$$S_{OLS} = \sum_{m \in \mathbb{M}} (\bar{b}_m - A f^m)^2 \quad (16)$$

を最小化することでパラメータ A および f を推定する。

お聞きしたいこと

卒論はどの研究を書くべきか？(ソサイエティの研究テーマか、NB の研究テーマか、両方か)：

compsac に採択される論文を書きたいです。今のテーマのまま研究を進めても先行研究と似た内容になってしまうことを恐れています。どのようなアクションをとればいいですか？：

- NB を改善する方向性で別の研究テーマを考える
- linkselfie のような、リンク選択問題に戻って別の研究テーマを考える
- 今の研究テーマのまま研究を進める (NB の WLS を検討する研究テーマ)
- それ以外のことをする

今週話したいこと

- ストーリー案トピックセンテンス
- 評価方法 (効率的な資源配分をどう示すか)

同数の *bounce* を使用した時の *estimated error* を比較する
サンプルサイズ 5 倍に増やして実験中。結果はまだ取れていない。

ストーリー案トピックセンテンス

title バウンス長ごとの非均一測定回数配分を許容するネットワークベンチマーキング拡張に関する一提案

背景 1: 量子ネットワークでは、効率的な忠実度推定をするプロトコルが考案されている：

- 量子ネットワークでは、リンクを測定し、忠実度の高いリンクを判別する際に、すべてのリンクに一律に測定を行うことはリソースの浪費となるため、有望なリンクに効率的にリソースを集中させる、リンク選択アルゴリズム、経路選択プロトコルが考案されている。

背景 2: 既存プロトコルは、NB を採用している：

- LinkSelFiE や QBGp 等の既存プロトコルは、ネットワークトポロジーの知識なしにリンクの平均忠実度を推定できるという特長から、Network Benchmarking (NB) をサブルーチンとして採用している。

背景 3: NB は複数のバウンス長に対して均一な測定回数で忠実度を推定する：

- NB は、あらかじめ定めた複数のバウンス長 $m \in \mathbb{M}$ それぞれに対して同一の測定回数を割り当て、得られた生存確率を指数モデルにフィッティングすることでリンクの忠実度を推定する手法である。

背景 4: NB には情報利得 (Fisher 情報量) が最大となる特定の m が存在する:

- NB において、情報利得を最大化する最適なバウンス長が定義でき、これを選択することで同一コストに対する不確実性の削減量を最大化できる。

動機: NB は均一配分の制約により効率的にリソース配分することができない:

- しかし、NB は全てのバウンス長に対して均一な測定回数を割り当てることを前提としており、情報利得の高いバウンス長に測定回数を集中させるような効率的なリソース配分ができない。

目的: NB を非均一配分可能なように拡張する:

- 本研究の目的は、NB を非均一配分可能なように拡張し、シミュレーションにより効率的な資源配分が可能になることを示す。

手法: 検討中。現在は重みつき最小二乗法で実装中
研究の問い:

- 非均一測定回数配分を許容することでリソース (総バウンス数) はどの程度削減できるのか?
- どのような配分戦略 (例: 情報利得に基づく配分) が最も効率的か?

主要な貢献:

- バウンス長ごとに異なる測定回数を許容する NB の拡張手法の提案
- シミュレーションによる提案手法のリソース削減効果の定量的評価

評価方法 (効率的な資源配分をどう示すか)

- 同じ総バウンス数のときに”相対不確かさ”をどれだけ減らせるかで比較する

(総バウンス数 = $\sum m \in M m$ のバウンス値 $\times$ サンプル数)
original の NB の実験設定と結果:

- バウンス数の範囲: 2~20 (19 点)

$m \in M = [2, 3, 4, \dots, 18, 19, 20]$ でそれぞれの m に対して 40 回のサンプル数を割りあてている。original の NB の総バウンス数は 8,360 回

結果

Network link fidelity = 0.899 ± 0.004

相対不確かさ: $0.004/0.899 \approx 0.44\%$

どのように比較する予定か:

- 同じ総バウンス数のときに”相対不確かさ”をどれだけ減らせるか

= どれだけ情報利得を獲得できたか

同数の bounce を使用した時の *estimated error* を比較する

手法によって cost ごとに存在するサンプル数が違うため、等分散性を仮定しないウェルチ検定 (Welch's t-test) によって統計検定を行なった。path の本数は 4 本。刻み幅は 500。サンプルサイズが十分にある部分だけ plot している。今回の実験結果では以下のような有意差があった。

1) Dephase (cost=1000): LinkSelFiE vs Vanilla NB

- p 値: 0.0106
- 平均差: 0.00323




Fig. 1. Amplitude Damping - Significance Visualization




Fig. 2. Bit-Flip - Significance Visualization

- t 統計量: 2.67

2) Depolar (cost=1500): LinkSelFiE vs Succ. Elim. NB

- p 値: 0.0329
- 平均差: 0.00035
- t 統計量: 2.19

linkselfie が統計的に有意に優れている箇所は検出されなかった。path の本数が 4 本では無い場合、サンプル数をさらに増やし、刻み幅をより小さくしたロバストな検証を追加で行なう予定。

今回の検証で分かったこと

linkselfie の実験設定では、1 リンクあたり 40 バウンス投資すると、高確率で忠実度が最も高いリンクを発見することが可能。

同数バウンス時の推定誤差において、linkselfie が統計的に優れている点は現時点では無い。(今後追加検証をする予定)




Fig. 3. Dephasing - Significance Visualization




Fig. 4. Depolarizing - Significance Visualization

この結果から分かること

linkselfie の実験設定で、最適リンク判別をするだけならば、1 リンクあたり 40 バウンス投資する、素朴な均等配分アルゴリズムで十分。(最適リンク判別をするだけならば、linkselfie のような高級なアルゴリズムを使う必要がない)

ここから考えたこと

1 リンクあたり 40 バウンス投資する、素朴な均等配分アルゴリズムよりも少ないバウンスで、最適リンク判別するにはどうすればいいのか。

考えた結果

忠実度推定のためにサブルーチンとしてアルゴリズム内部で使用されているネットワークベンチマーキング (NB) プロトコルを改善することで解決できるのではないかな

詳しい説明

linkselfie では 1 回の NB で 10 バウンス使用する設定。つまり 10 バウンス単位での測定をしている。

手法 1(現状)

link1 4NB(40 バウンス) → O

link2 4NB(40 バウンス) → X

link3 4NB(40 バウンス) → X

link4 4NB(40 バウンス) → X

これである程度判別可能。工夫すると以下のようにできるかもしれない

手法 2

link1 2NB → +1NB → 1NB → O

link2 2NB → +1NB → 1NB → X

link3 2NB → +1NB → X

link4 2NB → X

これでもいいが、4NB を振りわけただけでは面白くない。新規性がない。そこで以下のような方式を考えた

手法 3

link1 2NB → +0.5NB → +0.5NB → 0.3NB → O

link2 2NB → +0.5NB → +0.5NB → 0.3NB → X

link3 2NB → +0.5NB → +0.5NB → X

link4 2NB → +0.5NB → X

1NB あたりに使用するバウンス数をフェーズごとに変更できるようにするために、非均一測定回数配分を許容するネットワークベンチマーキング拡張が必要。特筆すべき点として、柔軟に資源配分できるだけではなく、1 バウンスから得られる情報量を増やすことが可能になることが挙げられる。手法 2

link3 2NB → +1NB → X 合計 30 バウンス

手法 3

link3 2NB → +0.5NB → +0.5NB → X 合計 30 バウンス

この例だと link3 に対して使われた総バウンスは手法 2 と 3 で同じである。普通に考えると手法 2 と 3 の link3 に対する忠実度の推定精度は同等であるはず。しかし、提案手法が実現できると 1 バウンスから得られる情報量を増やすことが可能になるため、手法 3 の推定精度が手法 2 の推定精度を上回るということが起こると考えている。

1NB から得られる情報量を増やすことが可能になっている点に新規性がある。NB の回数だけでなく、情報利得に基づいた適切なバウンス長 $m \in M$ も同時に制御することで大幅なコスト削減ができる可能性がある

ストーリー案トピックセンテンス

背景 1: 量子ネットワークでは、オンライン学習による忠実度推定が必要である: 量子ネットワークでは、ノイズにより品質が未知である多数の量子リンクの中から、忠実度の高いリンクを高精度で判定する際にすべて一様に測定を行うことはリソースの浪費となるため、測定から得られるフィードバックに基づき、逐次的意思決定を行うことで、効率的に有望なリンクにリソースを集中させる、オンライン学習に基づくリンク品質推定が必要である。

背景 2: オンライン推定を行う既存プロトコルは、NB を採用している: LinkSeLFiE や QBGp 等の既存プロトコルは、SPAM エラーとリンク品質を指数モデルへのフィッティングにより分離推定でき、トポロジーの知識を必要としない、Network Benchmarking (NB) をサブルーチンとして採用している。

背景 3: NB には情報利得 (Fisher 情報量) が最大となる特定の m が存在する: NB には、バウンス長 m に対して $2m$ 個のエンタングルメントペアを消費することから、1 エンタングルメントあたりの Fisher 情報量として定義される情報利得 $I(\pi, m) = 16A^2 m^{p(4m-2)}$ を最大化する、最適なバウンス長 $m^* = \arg \max \{m \in M\} I(\pi, m)$ が存在し、これを選択することで同一コストに対する不確実性の削減量を最大化できる。

背景 4: NB の均一配分するという制約がリンク選択、経路選択アルゴリズムと統合する際に障壁となっている: NB は全てのバウンス長に対して均一な測定回数を割り当てることを前提としており、LinkSeLFiE ではその制約が推定精度への寄与度が低いバウンス長にも無駄なリソースを消費する原因となっている。一方、QBGp では情報利得 (Fisher 情報量) が最大となる特定の m に測定を集中させる戦略をとるが、均一配分の制約により、 m^* を蓄積し、回帰することができないため、フィッティング係数 A は初期フェーズの推定値に固定され、ロバストに A を求められない可能性がある。

動機: 非均一配分を許容する NB の拡張が必要である: これらの問題を解決するために、情報利得の高いバウンス長に基づき探索効率を最大化でき、フィッティング係数 A をロバストに回帰できる、非均一配分を許容する NB の拡張が必要である

目的: 本研究の目的は、NB を非均一配分可能なように拡張することである:

手法:

今後の予定

linkselfie が行なった実験に誤解を生ませるような内容があることを主張する論文は保険として進めながら、今回提案したストーリー案の研究を並行して行なう予定。

E (Example : 具体例)

LinkSeLFiE が目指す「最小限の量子資源で、最も高忠実度なリンクを特定し、その忠実度を正確に推定する」という目的が、LinkSeLFiE よりもはるかに少ない資源と単純な戦略 (均等配分戦略) によっても十分に達成可能であることをシミュレーションによって示す。

VanillaNB は、各リンクを同じ回数だけベンチマークする単純な手法であり、LinkSeLFiE ではその繰り返し回数 T が 200 に設定されていた。

繰り返し回数の少ない均等配分戦略アルゴリズムの有効性を評価するために、今回の実験では $T=4$ と $T=20$ の Vanilla 4NB、Vanilla 20NB を実装し、LinkSeLFiE とこれらの均等配分戦略を比較する。

実験設定や各パラメータ設定は LinkSeLFiE と同じ実験設定で行なった。

• 実験の設定

我々は 2 つのノード（ソース S とデスティネーション D ）から成る単純なネットワークを構築し、その間に L 本のエンタングルメントリンクを配置する。各リンクは 4 種類の標準的な量子ノイズモデルに従う Depolarizing Noise（脱分極ノイズ）Dephasing Noise（位相緩和ノイズ）Amplitude Damping Noise（振幅減衰ノイズ）Bit-Flip Noise（ビット反転ノイズ）これらのノイズモデルのパラメータは、同一の忠実度値に対応するように変換されている。




Fig. 5. Amplitude Damping - Cost vs Path Number




Fig. 6. Bit-Flip - Cost vs Path Number




Fig. 7. Dephasing - Cost vs Path Number

まず、これらのリンク選択アルゴリズムにおける量子リソース消費を評価する。忠実度ギャップ $\Delta = 0.05$ を固定し、複数の量子エンタングルメントリンクで接続された 2 ノードの量子ネットワークをシミュレートする。それぞれのリンクは、忠実度 $1, 1 - \Delta, 1 - 2\Delta, \dots, 1 - (L -$




Fig. 8. Depolarizing - Cost vs Path Number

1) Δ を持つものとする。その後、各リンク選択アルゴリズムをネットワークに適用し、さまざまな L の値に対してアルゴリズムが終了する際の量子リソース消費量を測定する。ここで、量子リソース消費量の指標として総バウンス数を使用し、結果は 10 回の試行の平均をとった。Vanilla 4NB、Vanilla 20NB が LinkSeLFiE よりも少ない資源で配分できていることがわかる。バウンス数は $L = 7$ のときに Vanilla 20NB で LinkSeLFiE の半分以下、Vanilla 4NB は 1/10 ほどである。




Fig. 9. Amplitude Damping - Accuracy vs Path Number




Fig. 10. Bit-Flip - Accuracy vs Path Number




Fig. 11. Dephasing - Accuracy vs Path Number

次に、リンク選択アルゴリズムにおける最適リンク判別率を評価する。忠実度ギャップ $\Delta = 0.05$ を固定し、複数の量子エンタングルメントリンクで接続された 2 ノードの量子ネットワークをシミュレートする。それぞれのリンク




Fig. 12. Depolarizing - Accuracy vs Path Number

は、忠実度 $1, 1 - \Delta, 1 - 2\Delta, \dots, 1 - (L - 1)\Delta$ を持つものとする。その後、各リンク選択アルゴリズムをネットワークに適用し、さまざまな L の値に対してアルゴリズムの最適リンク判別率を測定する。ここで最適リンク判別率とはアルゴリズムが真の忠実度が最大のリンクを正しく選択できた確率のことである。結果は 10 回の試行の平均をとった。Vanilla 4NB、Vanilla 20NB では LinkSeLFiE と同等の判別率があることがわかる。