

Research Meeting

Shun Yamachika

Department of Informatics, School of Science and Technology
Kwansei Gakuin University
Sanda, Hyogo, Japan
shun@lsnl.jp

I. 今週話したいこと

- 同数の bounce を使用した時の estimated error を比較する
- ストーリー案トピックセンテンス
- 評価方法 (効率的な資源配分をどう示すか)

A. 同数の bounce を使用した時の estimated error を比較する

サンプルサイズ 5 倍に増やして実験中。結果はまだ取れていない。

B. ストーリー案トピックセンテンス

title バウンス長ごとの非均一測定回数配分を許容するネットワークベンチマーキング拡張に関する一提案

1) 背景 1: 量子ネットワークでは、効率的な忠実度推定をするプロトコルが考案されている:

- 量子ネットワークでは、リンクを測定し、忠実度の高いリンクを判別する際に、すべてのリンクに一樣に測定を行うことはリソースの浪費となるため、有望なリンクに効率的にリソースを集中させる、リンク選択アルゴリズム、経路選択プロトコルが考案されている。

2) 背景 2: 既存プロトコルは、NB を採用している:

- LinkSelFiE や QBGP 等の既存プロトコルは、ネットワークトポロジーの知識なしにリンクの平均忠実度を推定できるという特長から、Network Benchmarking (NB) をサブルーチンとして採用している。

3) 背景 3: NB は複数のバウンス長に対して均一な測定回数で忠実度を推定する:

- NB は、あらかじめ定めた複数のバウンス長 $m \in M$ それぞれに対して同一の測定回数を割り当て、得られた生存確率を指数モデルにフィッティングすることでリンクの忠実度を推定する手法である。

4) 背景 4: NB には情報利得 (Fisher 情報量) が最大となる特定の m が存在する:

- NB において、情報利得を最大化する最適なバウンス長が定義でき、これを選択することで同一コストに対する不確かさの削減量を最大化できる。

5) 動機: NB は均一配分の制約により効率的にリソース配分することができない:

- しかし、NB は全てのバウンス長に対して均一な測定回数を割り当てることを前提としており、情報利得の高いバウンス長に測定回数を集中させるような効率的なリソース配分ができない。

6) 目的: NB を非均一配分可能なように拡張する:

- 本研究の目的は、NB を非均一配分可能なように拡張し、シミュレーションにより効率的な資源配分が可能になることを示す。

7) 手法: 検討中。現在は重みつき最小二乗法で実装中

8) 研究の問い:

- 非均一測定回数配分を許容することでリソース (総バウンス数) はどの程度削減できるのか?
- どのような配分戦略 (例: 情報利得に基づく配分) が最も効率的か?

9) 主要な貢献:

- バウンス長ごとに異なる測定回数を許容する NB の拡張手法の提案
- シミュレーションによる提案手法のリソース削減効果の定量的評価

C. 評価方法 (効率的な資源配分をどう示すか)

- 同じ総バウンス数のときに“相対不確かさ”をどれだけ減らせるかで比較する

(総バウンス数 = $\sum m \in M m$ のバウンス値 $\times$ サンプル数)

1) original の NB の実験設定と結果:

- バウンス数の範囲: 2~20 (19 点)

$m \in M = [2, 3, 4, \dots, 18, 19, 20]$ でそれぞれの m に対して 40 回のサンプル数を割りあてている。original の NB の総バウンス数は 8,360 回

結果

Network link fidelity = 0.899 ± 0.004

相対不確かさ: $0.004/0.899 \approx 0.44\%$

2) どのように比較する予定か:

- 同じ総バウンス数のときに“相対不確かさ”をどれだけ減らせるか

= どれだけ情報利得を獲得できたか

D. 同数の bounce を使用した時の estimated error を比較する

手法によって cost ごとに存在するサンプル数が違うため、等分散性を仮定しないウェルチ検定 (Welch's t-test) によって統計検定を行なった。path の本数は 4 本。刻み幅は 500。サンプルサイズが十分にある部分だけ plot している。今回の実験結果では以下のような有意差があった。

1) Dephase (cost=1000): LinkSelFiE vs Vanilla NB




Fig. 1. Amplitude Damping - Significance Visualization




Fig. 2. Bit-Flip - Significance Visualization

- p 値: 0.0106
- 平均差: 0.00323
- t 統計量: 2.67

2) Depolar (cost=1500): LinkSelFiE vs Succ. Elim. NB

- p 値: 0.0329
- 平均差: 0.00035
- t 統計量: 2.19

linkselfie が統計的に有意に優れている箇所は検出されなかった。path の本数が 4 本では無い場合、サンプル数をさらに増やし、刻み幅をより小さくしたロバストな検証を追加で行なう予定。

E. 今回の検証で分かったこと

linkselfie の実験設定では、1 リンクあたり 40 バウンス投資すると、高確率で忠実度が最も高いリンクを発見することが可能。




Fig. 3. Dephasing - Significance Visualization




Fig. 4. Depolarizing - Significance Visualization

同数バウンス時の推定誤差において、linkselfie が統計的に優れている点は現時点では無い。(今後追加検証をする予定)

F. この結果から分かること

linkselfie の実験設定で、最適リンク判別をするだけならば、1 リンクあたり 40 バウンス投資する、素朴な均等配分アルゴリズムで十分。(最適リンク判別をするだけならば、linkselfie のような高級なアルゴリズムを使う必要がない)

G. ここから考えたこと

1 リンクあたり 40 バウンス投資する、素朴な均等配分アルゴリズムよりも少ないバウンスで、最適リンク判別をするにはどうすればいいのか。

H. 考えた結果

忠実度推定のためにサブルーチンとしてアルゴリズム内部で使用されているネットワークベンチマーキング (NB) プロトコルを改善することで解決できるのではないかと考えた。

I. 詳しい説明

linkselfie では 1 回の NB で 10 バウンス使用する設定。つまり 10 バウンス単位での測定をしている。

手法 1(現状)

link1 4NB(40 バウンス) → O
link2 4NB(40 バウンス) → X
link3 4NB(40 バウンス) → X
link4 4NB(40 バウンス) → X

これである程度判別可能。工夫すると以下のようにできるかもしれない

手法 2

link1 2NB → +1NB → 1NB → O
link2 2NB → +1NB → 1NB → X
link3 2NB → +1NB → X
link4 2NB → X

これでもいいが、4NB を振りわけただけでは面白くない。新規性がない。そこで以下のような方式を考えた

手法 3

link1 2NB → +0.5NB → +0.5NB → 0.3NB → O
link2 2NB → +0.5NB → +0.5NB → 0.3NB → X
link3 2NB → +0.5NB → +0.5NB → X
link4 2NB → +0.5NB → X

1NB あたりに使用するバウンス数をフェーズごとに変更できるようにするために、非均一測定回数配分を許容するネットワークベンチマーキング拡張が必要。特筆すべき点として、柔軟に資源配分できるだけではなく、1 バウンスから得られる情報量を増やすことが可能になることが挙げられる。手法 2

link3 2NB → +1NB → X 合計 30 バウンス

手法 3

link3 2NB → +0.5NB → +0.5NB → X 合計 30 バウンス
この例だと link3 に対して使われた総バウンスは手法 2 と 3 で同じである。普通に考えると手法 2 と 3 の link3 に対する忠実度の推定精度は同等であるはず。しかし、提案手法が実現できると 1 バウンスから得られる情報量を増やすことが可能になるため、手法 3 の推定精度が手法 2 の推定精度を上回るようなことが起こるかと考えている。

1NB から得られる情報量を増やすことが可能になっている点に新規性がある。NB の回数だけでなく、情報利得に基づいた適切なバウンス長 $m \in M$ も同時に制御することで大幅なコスト削減ができる可能性がある

J. ストーリー案トピックセンテンス

1) 背景 1: 量子ネットワークでは、オンライン学習による忠実度推定が必要である: 量子ネットワークでは、ノイズにより品質が未知である多数の量子リンクの中から、忠実度の高いリンクを高精度で判定する際にすべて一様に測定を行うことはリソースの浪費となるため、測定から得られるフィードバックに基づき、逐次的意思決定を行うことで、効率的に有望なリンクにリソースを集中させる、オンライン学習に基づくリンク品質推定が必要である。

2) 背景 2: オンライン推定を行う既存プロトコルは、NB を採用している: LinkSeLFiE や QBGP 等の既存プロトコルは、SPAM エラーとリンク品質を指数モデルへのフィッティングにより分離推定でき、トポロジーの知識を必要としない、Network Benchmarking (NB) をサブルーチンとして採用している。

3) 背景 3: NB には情報利得 (Fisher 情報量) が最大となる特定の m が存在する: NB には、バウンス長 m に対して $2m$ 個のエンタングルメントペアを消費することから、1 エンタングルメントあたりの Fisher 情報量として定義される情報利得 $I(\pi, m) = 16A^2 m^p (4m-2)^j$ を最大化する、最適なバウンス長 $m^* = \arg \max \{m \in M\} I(\pi, m)$ が存在し、これを選択することで同一コストに対する不確実性の削減量を最大化できる。

4) 背景 4: NB の均一配分するという制約がリンク選択、経路選択アルゴリズムと統合する際に障壁となっている: NB は全てのバウンス長に対して均一な測定回数を割り当てることを前提としており、LinkSeLFiE ではその制約が推定精度への寄与度が低いバウンス長にも無駄なリソースを消費する原因となっている。一方、QBGP では情報利得 (Fisher 情報量) が最大となる特定の m に測定を集中させる戦略をとるが、均一配分の制約により、 m を蓄積し、回帰することができないため、フィッティング係数 A は初期フェーズの推定値に固定され、ロバストに A を求められない可能性がある。

5) 動機: 非均一配分を許容する NB の拡張が必要である: これらの問題を解決するために、情報利得の高いバウンス長に基づき探索効率を最大化でき、フィッティング係数 A をロバストに回帰できる、非均一配分を許容する NB の拡張が必要である

6) 目的: 本研究の目的は、NB を非均一配分可能なように拡張することである:

7) 手法:

K. 今後の予定

linkselfie が行なった実験に誤解を生ませるような内容があることを主張する論文は保険として進めながら、今回提案したストーリー案の研究を並行して行なう予定。

L. E (Example: 具体例)

LinkSeLFiE が目指す「最小限の量子資源で、最も高忠実度なリンクを特定し、その忠実度を正確に推定する」とい

う目的が、LinkSeLFiE よりもはるかに少ない資源と単純な戦略 (均等配分戦略) によっても十分に達成可能であることをシミュレーションによって示す。

VanillaNB は、各リンクを同じ回数だけベンチマークする単純な手法であり、LinkSeLFiE ではその繰り返し回数 T が 200 に設定されていた。

繰り返し回数の少ない均等配分戦略アルゴリズムの有効性を評価するために、今回の実験では $T=4$ と $T=20$ の Vanilla 4NB、Vanilla 20NB を実装し、LinkSeLFiE とこれらの均等配分戦略を比較する。

実験設定や各パラメータ設定は LinkSeLFiE と同じ実験設定で行なった。

● 実験の設定

我々は 2 つのノード (ソース S とデスティネーション D) から成る単純なネットワークを構築し、その間に L 本のエンタングルメントリンクを配置する。各リンクは 4 種類の標準的な量子ノイズモデルに従う Depolarizing Noise (脱分極ノイズ) Dephasing Noise (位相緩和ノイズ) Amplitude Damping Noise (振幅減衰ノイズ) Bit-Flip Noise (ビット反転ノイズ) これらのノイズモデルのパラメータは、同一の忠実度値に対応するように変換されている。




Fig. 5. Amplitude Damping - Cost vs Path Number




Fig. 6. Bit-Flip - Cost vs Path Number




Fig. 7. Dephasing - Cost vs Path Number

まず、これらのリンク選択アルゴリズムにおける量子リソース消費を評価する。忠実度ギャップ $\Delta = 0.05$ を固定




Fig. 8. Depolarizing - Cost vs Path Number

し、複数の量子エンタングルメントリンクで接続された2ノードの量子ネットワークをシミュレートする。それぞれのリンクは、忠実度 $1, 1 - \Delta, 1 - 2\Delta, \dots, 1 - (L - 1)\Delta$ を持つものとする。その後、各リンク選択アルゴリズムをネットワークに適用し、さまざまな L の値に対してアルゴリズムが終了する際の量子リソース消費量を測定する。ここで、量子リソース消費量の指標として総バウンス数を使用し、結果は10回の試行の平均をとった。Vanilla 4NB、Vanilla 20NB が LinkSelFiE よりも少ない資源で配分できていることがわかる。バウンス数は $L = 7$ のときに Vanilla 20NB で LinkSelFiE の半分以下、Vanilla 4NB は $1/10$ ほどである。




Fig. 9. Amplitude Damping - Accuracy vs Path Number




Fig. 10. Bit-Flip - Accuracy vs Path Number




Fig. 11. Dephasing - Accuracy vs Path Number

次に、リンク選択アルゴリズムにおける最適リンク判別率を評価する。忠実度ギャップ $\Delta = 0.05$ を固定し、複数




Fig. 12. Depolarizing - Accuracy vs Path Number

の量子エンタングルメントリンクで接続された2ノードの量子ネットワークをシミュレートする。それぞれのリンクは、忠実度 $1, 1 - \Delta, 1 - 2\Delta, \dots, 1 - (L - 1)\Delta$ を持つものとする。その後、各リンク選択アルゴリズムをネットワークに適用し、さまざまな L の値に対してアルゴリズムの最適リンク判別率を測定する。ここで最適リンク判別率とはアルゴリズムが真の忠実度が最大のリンクを正しく選択できた確率のことである。結果は10回の試行の平均をとった。Vanilla 4NB、Vanilla 20NB では LinkSelFiE と同等の判別率があることがわかる。